

***Facultad
de
Ciencias***

**DESARROLLO DE IA DE PRONÓSTICO DE
INSTALACIÓN FOTOVOLTAICA
(AI DEVELOPMENT FOR PHOTOVOLTAIC
INSTALLATION FORECASTING)**

Trabajo de Fin de Grado
para acceder al

GRADO EN INGENIERÍA INFORMÁTICA

Autor: Guillermo Blanco Gala

Director: Camilo Palazuelos Calderón

Co-Director: Alejandro Pérez Núñez

Junio – 2026

Tabla de contenido

RESUMEN	5
ABSTRACT	5
ÍNDICE DE FIGURAS	6
ÍNDICE DE ECUACIONES	6
ÍNDICE DE TABLAS	7
1. INTRODUCCIÓN	9
1.1 MOTIVACIÓN Y OBJETIVO	9
1.2 ENERGÍA FOTOVOLTAICA.....	13
1.2.1 SITUACIÓN ACTUAL DE LA FOTOVOLTAICA.....	15
1.2.2 IMPACTO AMBIENTAL.....	17
1.2.3 IMPACTO ECONÓMICO	19
1.3 ALCANCE DEL PROYECTO	20
2. METODOLOGÍA	21
2.1 PASOS PREVIOS	21
2.1.1 POTENCIALES MODELOS.....	21
2.1.2 APRENDIZAJE CONJUNTO	23
2.1.3 PREPARACIÓN DEL DATASET	24
2.1.4 SIMPLE TREE	27
2.1.5 HERRAMIENTAS.....	29
2.2 MODELADO	30
2.2.1 ESCALADO	31
2.2.2 ENTRENAMIENTO	33
2.2.3 OVERFITTING	34
2.3 PREDICCIÓN	36
2.3.1 REPRESENTACIÓN GRÁFICA.....	36
2.3.2 MÉTRICAS DE PREDICCIÓN.....	40
2.3.3 PREDICCIÓN CRUZADA	41
2.4 APLICACIONES PRÁCTICAS	42
3. PASOS FUTUROS	45
4. CONCLUSIONES	47
REFERENCIAS	49

RESUMEN

La industria fotovoltaica es una de las más presentes dentro del campo de la energía renovable, siendo España un país referente en este sector. Así pues, la planificación de la producción de una planta fotovoltaica es clave para poder administrar el plan energético del lugar beneficiario.

En este trabajo, se detallará el desarrollo de un modelo de predicción, entrenado mediante la explotación de datos provenientes de dos plantas pilotos de fotovoltaica flotante o fija, ambas reales y pertenecientes a plantas piloto de CTC (Centro Tecnológico de Componentes). En base a este modelo, será posible conocer la potencia generada esperada y administrar las cargas de consumo energético de forma óptima.

El contenido se enfocará tanto en las herramientas utilizadas para el desarrollo como en el ciclo de vida del proyecto, exponiendo las dificultades que surgieron durante este y como se solucionaron.

Palabras clave: IA, Fotovoltaica, Aprendizaje automático, Energía renovable, Minería de datos.

ABSTRACT

The photovoltaic industry is one of the mains inside the field of renewable energy, with Spain being one of its headliners. Therefore, the planification of the photovoltaic plant production is key to administrate the energetic plan of the beneficiary.

This project will detail the development of a prediction model, trained through the exploit of data coming from pilot photovoltaic plants, floating or fixed, both real and belonging to CTC (Centro Tecnológico de Componentes) pilot plants. In base of this model, it will be possible to know the expected generated power and administrate the energetic charges in an optimum way.

The content will focus both on the tools used in the development and the project's life cycle, exposing the difficulties found through the process and how they were solved.

Key words: AI, Photovoltaic, Automatic learning, Renewable energy, Data mining.

ÍNDICE DE FIGURAS

Ilustración 1 - Publicaciones anuales sobre fotovoltaica. Fuente: Datawise	10
Ilustración 2 - Clústeres distribución de palabras clave. Fuente: Datawise	10
Ilustración 3 - Curvas de demanda de cada sector. Fuente: IEEE	13
Ilustración 4 - Evolución de la fotovoltaica instalada en España. Fuente: statista.com ..	16
Ilustración 5 - Porcentaje de aportación a la energía eléctrica. Fuente: ree.es	16
Ilustración 6 - Datos antes de interpolar (CTC)	26
Ilustración 7 - Datos tras interpolar (CTC).....	26
Ilustración 8 - SimpleTree	27
Ilustración 9 - Predicción 24h SimpleTree	28
Ilustración 10 - Predicción 48h SimpleTree	28
Ilustración 11 - Mapa de calor (CTC)	32
Ilustración 12 - Mapa de calor (Lorca).....	32
Ilustración 13 - Detección de overfitting sin early stop.....	35
Ilustración 14 - Detección de overfitting con early stop	35
Ilustración 15 - Predicciones CTC	36
Ilustración 16 - Predicciones Lorca	36
Ilustración 17 - Predicción 24h CTC.....	37
Ilustración 18 - Predicción 48h CTC.....	37
Ilustración 19 - Comparación predicción realidad antes de interpolación (CTC).....	38
Ilustración 20 - Comparación predicción realidad tras interpolación (CTC)	38
Ilustración 21 - Comparativa predicción realidad (Lorca)	39
Ilustración 22 - Predicción mañana/tarde (Lorca)	42
Ilustración 23 - Predicción mañana/tarde (CTC).....	42
Ilustración 24 - Media mañana/tarde (CTC).....	43
Ilustración 25 - Media mañana/tarde (Lorca)	43
Ilustración 26 - Ejemplo consulta de media	46

ÍNDICE DE ECUACIONES

Ecuación 1 - Demanda.....	11
Ecuación 2 - Cálculo demanda base	12
Ecuación 3 - Cálculo de demandas pico	12
Ecuación 4 - Cálculo del ruido en la demanda	12
Ecuación 5 - Normalizar demanda	12
Ecuación 6 - Función booleana de outlier	25
Ecuación 7 - Interpolación lineal.....	26
Ecuación 8 - Escalamiento con MinMaxScaler.....	31
Ecuación 9 - Normalización diferencia a mediodía.....	37
Ecuación 10 - Mean Absolute Error	40
Ecuación 11 - Mean Squared Error	40
Ecuación 12 - Root Mean Squared Error	40
Ecuación 13 - Coeficiente de determinación.....	41

ÍNDICE DE TABLAS

Tabla 1 - Demanda según sector Fuente: IEEE	13
Tabla 2 - Comparativa instalación conectada a red y aislada.....	14
Tabla 3 - Métricas SimpleTree	28
Tabla 4 - Importancia de variables (CTC).....	34
Tabla 5 - Importancia de variables (Lorca).....	33
Tabla 6 - Métricas antes de irr_ideal (CTC).....	40
Tabla 7 - Métricas después de irr_ideal (CTC).....	39
Tabla 8 - Métricas antes de irr_ideal (Lorca).....	39
Tabla 9 - Métricas después de irr_ideal (Lorca)	39
Tabla 10 - Predicción datos Lorca con modelo CTC	41
Tabla 11 - Predicción datos CTC con modelo Lorca.....	41

1. INTRODUCCIÓN

1.1 MOTIVACIÓN Y OBJETIVO

El mercado fotovoltaico español está dividido en dos partes atendiendo a su situación dentro de la red eléctrica. Los productores son aquellos que se conectan y venden su energía a la red eléctrica española. Este sector representa aproximadamente el 26% de la energía en España, y está creciendo significativamente alrededor de un 15% anual. Por otro lado, los autoconsumidores son normalmente instalaciones de menor dimensión que encuentran dificultades en la venta de su energía, por lo que, aun estando conectadas a la red, no vierten en ella su excedente energético. Los sectores más representativos de este caso son el industrial y el residencial. Sorprendentemente, los autoconsumidores están disminuyendo su número cerca del 32% al año, prácticamente el doble de rápido de lo que crece su contraparte, los productores. Es de vital importancia plantearse el porqué de esta situación.

En España, se ha implementado una barrera de regulación que, cada vez más, ha ido restringiendo las instalaciones fotovoltaicas. Estos requerimientos provocan que las instalaciones deban desembolsar grandes cantidades de inversión para satisfacer las exigencias que la red les impone para su conexión. Para más inri, las instalaciones autoconsumidoras, en la mayoría de los casos con una producción inferior a 100kWp, están sujetas a la regla de inyección cero.

La regla de inyección cero es aquella que prohíbe la inyección del excedente de producción de la instalación en la red eléctrica. Entonces, los autoconsumidores deben o ajustar la producción fotovoltaica a la demanda energética de la planta, o interrumpir la producción cuando se llenen las baterías, en caso de haberlas. Por lo tanto, es clave un sistema de predicción de producción fotovoltaica para poder gestionar adecuadamente las cargas y consumos en los casos de inyección cero.

La flexibilidad energética en este contexto define la capacidad de adaptación del consumo en función de factores externos como tarifas o imposiciones. Estudios revelan que se puede alcanzar un ahorro de entre 20-25% cuando el control predictivo de la producción es aplicado, a la vez que contribuye a reducir la emisión de CO₂ a la atmósfera. El incremento de complejidad en los sistemas energéticos y la urgencia de sostenibilidad han provocado grandes avances en los sistemas de control energético (EMS). Estos sistemas son clave a la hora de optimizar el consumo energético, mejorando la eficiencia e integrando fuentes de energía renovable en diversos sectores.

Desarrollo de IA de pronóstico de producción fotovoltaica

En los últimos años, hemos experimentado un incremento de publicaciones en el ámbito de la optimización de los sistemas de control energéticos, especialmente a partir de 2010. Esta actividad se mantuvo en mínimos hasta 2005, creciendo hasta las casi 200 publicaciones anuales en el año 2020. Este incremento destaca la importancia del crecimiento en este campo, provocado por avances en técnicas de optimización, eficiencia energética y el incentivo mundial de construir hábitos productivos sostenibles.




Ilustración 1 - Publicaciones anuales sobre fotovoltaica. Fuente: Datawise

De los documentos se rescataron y recogieron en clústeres las palabras más repetidas, siendo la mayoría las relacionadas con los sistemas de control energético y optimización.




Ilustración 2 - Clústeres distribución de palabras clave. Fuente: Datawise

El clúster verde se centra en la eficiencia energética y construcciones inteligentes. Hace especial énfasis en los sistemas de control energético y su relación con la toma de decisiones en lo que a eficiencia energética se refiere. Las palabras clave pertenecientes a este clúster incluyen “eficiencia energética”, “inteligencia artificial”, “aprendizaje profundo”, “aprendizaje automático”, entre otras. Es por eso por lo que destaca el uso de herramientas de procesamiento avanzado para optimizar el uso de los sistemas de control energético. Uno de los propósitos más comunes en esta área es la reducción del consumo energético y la mejora de la sostenibilidad mediante tecnologías como IOT (Internet of Things), control inteligente y analíticas de predicción.

El clúster rojo se centra en energía renovable y optimización. Destaca la integración de energías renovables en los sistemas de control energético. Explora las técnicas de optimización para incorporar tecnologías de energía renovable, como los paneles fotovoltaicos, las baterías y las microrredes en entornos de control de energía. En resumen, enfatiza el desarrollo de estrategias para integrar energía limpia en infraestructuras existentes.

El clúster azul se centra en redes inteligentes y sistemas de control energético locales, en instalaciones residenciales. Esta área explora la automatización, la organización y la reducción de costes en las estrategias de control de energía y su integración con tecnologías de red inteligente. Incluye usar dispositivos inteligentes para optimizar el consumo, implementar mecanismos de respuesta y mejorar la resiliencia a través de sistemas de control y organización avanzados.

La optimización se puede dividir en dos dependiendo de su duración en el tiempo. La optimización a corto plazo se centra en la producción horaria de almacenamiento de energía para minimizar costes e incrementar la eficiencia en un corto periodo de tiempo. La optimización a largo plazo busca determinar las dimensiones de componentes óptimas para asegurar la eficiencia mientras que minimiza la inversión y los costes. Dado que el balance de carga esta generalmente medido en una base horaria suficiente para captar las fluctuaciones del valor de mercado energético y la generación de energías renovables, la mayoría de estos sistemas también se centran en la optimización horaria mediante intervalos de simulación del comportamiento esperado del almacenamiento de la batería. Para calcular la demanda de una instalación, hay que tener en cuenta diversos factores en función del tiempo (t):

$B(t)$, que representa el ciclo de trabajo básico. Las demandas pico, $P(t)$, que introducen los eventos de máxima demanda no superpuestos. El ruido, $N(t)$, que mide las fluctuaciones de ruido estocásticas. Por último, A denota el nivel de consumo base, asegurando condiciones realistas a nivel operacional y no operacional. Por lo tanto, la fórmula para calcular la demanda total, $D(t)$, es:

$$D(t) = B(t) + P(t) + N(t) + A$$

Ecuación 1 - Demanda

Modelar las fluctuaciones diarias de la demanda requiere una función que pueda transicionar entre estados operacionales y no operacionales. La demanda base se define como:

$$B(t) = B_{CON} * \frac{\tanh(k_1(t - T_{start})) - \tanh(k_2(t - T_{end}))}{2}$$

Ecuación 2 - Cálculo demanda base

Donde B_{con} es el consumo medio durante ciclos de trabajo. Se recoge aleatoriamente de una distribución uniforme dentro del rango específico para asegurar valores realistas. k_1 y k_2 permiten controlar el gradiente de la pendiente, asegurando un incremento y decremento gradual en la demanda. T_{start} y T_{end} definen las horas de trabajo dentro de un rango de 24 horas.

Las demandas pico se dan debido a la activación de componentes, periodos de alta producción o urgencias de demanda repentinas. La demanda pico total es la suma de todas las demandas pico:

$$P(t) = \sum_{i=1}^{Np} P_i * \exp\left(-\frac{(t - T_i)^2}{2\sigma^2}\right)$$

$$\text{Donde } P_i = \begin{cases} X_i * A_p, & \text{Si } X_i \geq 0.4 \\ 0, & \text{Si } X_i < 0.4 \end{cases}$$

Ecuación 3 - Cálculo de demandas pico

Esta función es normalizada para asegurarse de que $P(t)$ se mantiene dentro del rango $P(t) \leq A_p$.

Introducir perturbaciones estocásticas mejora la representación del conjunto de datos, haciendo que reflejen mejor el histórico de datos.

$$N(t) = \min(\max(\epsilon(t), -noise_{max}), noise_{max})$$

Ecuación 4 - Cálculo del ruido en la demanda

$\epsilon(t)$ es una distribución normal con media de cero y desviación estándar de 0.05.

Por último, A se encarga de que la demanda se mantenga dentro del rango normalizado $[0,1]$.

$$A = 1 - B_{max} - A_p - noise_{max}$$

Ecuación 5 - Normalizar demanda

La siguiente tabla recoge los datos de demanda de una muestra de 50 perfiles para diferentes sectores[1]:

Sector	$(T_{start} - T_{end})$	$(B_{min} - B_{max})$	$(k_1 - k_2)$	Picos	Intervalo de tiempo de picos	A_p	σ_{peak}	$noise_{ma}$
Industria pesada	Continuo	0		0-2	(0-24), (0-24)	0.2	1.5	0.1
Agrícola y logístico	5 - 22	(0.3, 0.5)	0.8 - 1.2	0-2	(0-5), (11-19)	0.4	2	0.08
Comercio	8 - 22	(0.3, 0.5)	0.5 - 0.8	0-2	(10-14), (17-19)	0.35	1.8	0.1
Hospitales y sector sanitario	7 - 22	(0.05, 0.2)	0.3 - 0.3	0-3	(2-8), (10-12), (16-18)	0.15	2.5	0.12
Automóvil	6 - 21	(0.4, 0.6)	0.6 - 1.0	0-2	(10-12), (16-19)	0.3	1.5	0.07

Tabla 1 - Demanda según sector Fuente: IEEE

La siguiente figura representa la demanda normalizada de cada sector:




Ilustración 3 - Curvas de demanda de cada sector. Fuente: IEEE

Este trabajo estudiará una posible solución al problema de la correcta administración energética de una planta en la situación de inyección cero.

1.2 ENERGÍA FOTOVOLTAICA

La energía fotovoltaica es la energía renovable mediante la cual se convierte radiación emitida por el sol en electricidad. Para ello, lleva a cabo el siguiente proceso de producción: la luz solar incide sobre la placa fotovoltaica, haciendo que los fotones impacten en el material semiconductor. Tras esto, la energía proporcionada por los fotones desplaza los electrones del semiconductor, creando pares electrón-hueco. Hay dos placas en las células solares, una con carga negativa y otra con carga positiva, por lo que se genera un campo eléctrico en medio de ambas.

El campo eléctrico generado entre las placas fuerza a los electrones liberados a desplazarse en un sentido concreto, creando corriente continua. Para poder realizar el proceso de producción correctamente, la instalación necesita diversos componentes, siendo estos: Paneles solares, conformados por varias células fotovoltaicas conectadas en serie o en paralelo. Inversor solar, debido a que la generación de corriente de los paneles produce corriente continua, es necesario un inversor que la convierta en corriente alterna, la utilizada en la red eléctrica. Estructura, los paneles han de colocarse con la orientación e inclinación óptimas para obtener la mayor cantidad de luz solar diaria posible. Sistema de monitorización, que posibiliten el seguimiento de la producción y la detección de posibles fallos de rendimiento o seguridad. También, pueden contar con otros componentes opcionales, como baterías, para almacenar la energía producida y poder usarla en días nublados o de noche, y reguladores de carga, encargados de administrar las baterías y evitar sobrecargas.

Atendiendo a su situación respecto a la red eléctrica, las instalaciones fotovoltaicas pueden ser conectadas a la red o aisladas. Estas presentan diversas diferencias entre sí:

Las conectadas a la red están integradas dentro de la red eléctrica, por lo que se ven influenciadas por las fluctuaciones en el mercado energético. Primero consumen su producción y, en caso de necesitar más energía, la compran de la red eléctrica. También puede darse el caso de que la producción exceda el consumo, caso en el que se inyectaría el excedente en la red eléctrica, obteniendo una compensación económica (salvo en los casos de inyección cero, como hemos visto anteriormente). Las aisladas no están integradas dentro de la red eléctrica, por lo que son independientes al mercado energético. En este tipo de instalación, se consume exclusivamente lo generado y almacenado en las baterías. En algunos casos, es posible la implementación de un generador extra, alimentado por diésel o gasolina.

En la siguiente tabla se reflejan las principales diferencias entre ambos tipos de instalación:

	Conectada a red	Aislada
Inversión inicial	Menor (Puede no incluir baterías)	Mayor (Obligatorio uso de baterías)
Autonomía	Parcial	Absoluta
Fiabilidad	Alta, al tener la red como respaldo	Variable
Coste de factura eléctrica	Notablemente disminuido	Inexistente
Complejidad	Baja	Media

Tabla 2 - Comparativa instalación conectada a red y aislada

Para analizar la capacidad de una planta fotovoltaica, es importante diferenciar entre potencia pico y potencia nominal[2]. La potencia pico es la cantidad de kW instalados, mientras que la potencia nominal es la potencia del inversor, es decir, la potencia que este puede procesar. La que marca la producción es la nominal, ya que no se puede producir más potencia de la que se puede transformar, no obstante, se instala una potencia de pico superior a la nominal, para asegurarse de cubrir la capacidad del inversor en su totalidad. De esta forma, se crea un cuello de botella entre los kW instalados y los que el inversor es capaz de transformar. Para un correcto diseño hay que tratar de reducir al mínimo posible la diferencia de potencial entre la potencia pico y la nominal, asegurándose siempre de que la pico sea superior.

Es esencial supervisar el rendimiento de la instalación, ya que posibles agentes externos como la suciedad pueden obstruir la capacidad productiva de la planta. Es por ello por lo que el mantenimiento es clave, no solo por la limpieza, sino por la posibilidad de que los paneles se desalineen o no estén en la inclinación óptima para captar la máxima irradiancia solar posible. Uno de los principales indicadores de eficiencia es el rendimiento energético[3], el cual es el resultado de dividir la energía generada entre la energía máxima. Si el rendimiento es elevado quiere decir que la instalación está teniendo un buen desempeño. Existen diversas tecnologías para evaluar el rendimiento de una instalación fotovoltaica, como los simuladores solares o los medidores de radiación solar. Los simuladores son herramientas software que nos permiten simular una situación en función de factores como la radiación, la inclinación, entre otros, y nos ayudan a dimensionar y estimar la energía que generará en dicha situación. Los medidores de radiación solar son dispositivos que miden la radiación en un determinado lugar e instante. De esta forma, podemos comprobar lo adecuada que es una zona para una planta fotovoltaica antes de su instalación. Por último y más importante, los sistemas de monitoreo miden y registran en tiempo real los diferentes parámetros de la instalación, y brindan información valiosa sobre el rendimiento.

1.2.1 SITUACIÓN ACTUAL DE LA FOTOVOLTAICA

España ha realizado un hito histórico al pasar de 11GW de potencia instalada en 2020 a más de 32GW a finales de 2024[4], convirtiendo así a la fotovoltaica en la tecnología con mayor potencia instalada, superando incluso a la eólica. Actualmente, la solar fotovoltaica aporta el 17% de toda la energía eléctrica a nivel nacional [5], posicionando a España como uno de los líderes europeos en energía solar.




Ilustración 4 - Evolución de la fotovoltaica instalada en España. Fuente: statista.com




Ilustración 5 - Porcentaje de aportación a la energía eléctrica. Fuente: ree.es

La fotovoltaica en España también cuenta con una inversión importante en I + D + i, contando con más del doble de activos que la media de las empresas en el país, con cantidades que rondan los 500 millones de euros, entre el 3% y 4% de sus ingresos totales[6].

A pesar de estos logros, la fotovoltaica presenta diversos desafíos, siendo el precio de la energía el más destacado. Al ser un sector con una proliferación tan rápida, la competencia interna se ha visto incrementada enormemente, lo que ha desembocado en una reducción del precio de venta de la energía solar. Esta situación ha afectado a la rentabilidad de las plantas, al generar fluctuaciones notables en los precios[7]. Si no se toman medidas correctivas, se espera que la situación empeore de cara a finales de 2026.

Una de las potenciales soluciones a este problema sería el aumento del uso de sistemas de almacenamiento de energía en baterías (BESS). Estas instalaciones permiten la distribución equilibrada de la energía, estabilizando los precios de la energía solar.

Por otro lado, es interesante la posibilidad de hibridar la fotovoltaica con otra fuente de energía renovable, como la eólica. De esta forma, la instalación puede seguir generando energía aun cuando las condiciones atmosféricas imposibiliten la producción de una de las dos fuentes. La tramitación para proyectos de este tipo varía según qué fuentes se deseen combinar, ya que no existe una normativa general para proyectos de generación renovable híbrida.

Internacionalmente, la fotovoltaica representa el 46% de la capacidad renovable mundial, y la IEA (International Energy Agency) estima alrededor de 3,6TW de energía renovable nueva antes de 2030, aportando la fotovoltaica el 80% de estas adiciones renovables. Esta tecnología está en la vanguardia de las adiciones de energía renovable, con España batiendo récords de generación a nivel internacional. Conforme se vaya acercando el año 2030, la fotovoltaica incrementará su presencia como la principal fuente renovable de energía.

1.2.2 IMPACTO AMBIENTAL

El impacto al medio ambiente producido por la energía fotovoltaica es prácticamente nulo, ya que no involucra ningún proceso químico ni expulsa sustancias contaminantes a la atmósfera, como ocurre con la quema de combustibles fósiles, por lo que podemos concluir que el proceso de generación de la energía fotovoltaica no contribuye al calentamiento global.

Por otro lado, cabe aclarar que el proceso de fabricación de los paneles solares no presenta resultados tan positivos ambientalmente hablando, debido a que el proceso de fabricación involucra materiales que pueden resultar tóxicos, como el cadmio y el plomo. Además, uno de los argumentos principales de los detractores de la energía fotovoltaica (y de la energía renovable en general) es el impacto visual que provoca. Para las grandes instalaciones de paneles fotovoltaicos se requiere una gran extensión de terreno que, normalmente, se ubica en campos fuera de las ciudades. La instalación en estos campos provoca una cierta disconformidad en parte de la población local, al sentirla intrusiva. No obstante, es común encontrar instalaciones en terreno arrendado, es decir, alquilado durante un aproximado de 25 años, tras los cuales la instalación se retira y, al no contaminar el suelo, no deja secuelas en el terreno tras su retirada. En cuanto al suelo ocupado, se admira una relación m^2/GWh más favorable en la fotovoltaica que en fuentes no renovables. Por ejemplo, la quema de carbón ocupa un área promedio de 3642m^2 para producir un GWh, mientras que la fotovoltaica 3237m^2 , un 12% menos. Aunque es una fuente de energía más eficiente espacialmente hablando que el carbón, aún sigue lejos de los $1335\text{m}^2/\text{GWh}$ de la energía eólica[8].

Los paneles solares, tras ser desmontados, deben formar parte de un proceso de reciclaje para evitar la generación de residuos innecesarios. El porcentaje de paneles que pueden reciclarse asciende hasta un 90%, por lo que estamos ante un ciclo de vida casi perfecto[9]. El proceso consiste en el desmontado de los paneles y su separación del resto de componentes, para así poder enviarlos a una instalación de reciclaje especializada en este tipo de tecnologías.

En comparación con otras energías renovables, la fotovoltaica obtiene resultados mucho más positivos en lo que a impacto ambiental se refiere. Las alteraciones producidas durante su proceso de fabricación son inferiores a otros tipos de producción, como la eólica. Es por eso por lo que los paneles solares son una fuente de energía destacablemente sostenible. En 2019, se estima que la energía fotovoltaica evitó la emisión de 7 millones de toneladas de CO₂ a la atmósfera, cantidad equivalente a 3 millones de coches en circulación a lo largo de un año[10].

La producción de la misma cantidad de energía en una central térmica de carbón, en pequeña escala, supone la emisión de 20 veces el dióxido de carbono que emitiría la fabricación de módulos solares necesarios para esa extensión productiva. En gran escala, esta diferencia se acentúa aún más, siendo cerca de 200 veces menos la cantidad de dióxido de carbono emitido por todo el proceso de producción fotovoltaico respecto a su contraparte carbonífera, incluyendo los procesos de fabricación y reciclaje[8]. Todos los compuestos y procesos utilizados durante la producción de los paneles son ya utilizados en la industria metalúrgica, por lo que no se introducen nuevos factores a considerar dentro de esta cadena. Actualmente, la investigación en la fabricación de paneles solares se centra en reducir las pérdidas del material utilizado durante la producción, reduciendo así no solo los costes sino la emisión de contaminantes generados.

Hay varias iniciativas para emplear la fotovoltaica como herramienta de mejora de la producción no energética. Un ejemplo de esto es la agrovoltaje, la cual da un doble uso al suelo. Se instalan paneles solares y, debajo, se cultivan alimentos que no requieran mucha luz para su crecimiento. También, permite reducir el estrés hídrico y protege los cultivos frente a granizos o heladas. En el caso de las instalaciones flotantes, permiten disminuir la evaporación del agua de embalses al bloquear la luz y calor del sol.

Pese al proceso ciertamente contaminante de la fabricación de los paneles y el impacto visual provocado en los campos, sigue siendo infinitamente inferior al daño evitado. Hoy en día, se trabaja para minimizar el impacto ambiental en la medida de lo posible.

1.2.3 IMPACTO ECONÓMICO

En los últimos años la energía fotovoltaica se ha visto impulsada por políticas gubernamentales favorables, lo que ha provocado que genere un impacto significativo en la economía española. Según el IDAE (Instituto para la Diversificación y Ahorro de la Energía), la solar fotovoltaica generó alrededor de 5.900 millones de euros en España en el año 2019[11].

Aunque la instalación fotovoltaica requiere una inversión inicial bastante elevada, se estima un retorno de la inversión de entorno al 15% anual, tardando entre 5 y 7 años en recuperarla, por lo que, al tener unos 25 años de vida útil, las próximas dos décadas tendría una generación de energía gratuita, lo que disminuye enormemente (incluso totalmente, como vimos en las instalaciones aisladas) el gasto energético.

También es remarcable el aumento del valor de la propiedad en caso de contar con una instalación fotovoltaica, que puede ascender a un valor entre el 3% y 10%, dependiendo de la ubicación, tamaño y eficiencia. En casos realmente favorables, el porcentaje puede llegar al 25% del valor de la vivienda[12]. Este factor también genera interés en potenciales compradores, especialmente si la vivienda cuenta con una certificación energética, debido al ahorro y sostenibilidad que esto implica.

A su vez, al tratarse de un sector en auge, se estima que la fotovoltaica ha generado más de 190.000 puestos de trabajo en España para el año 2022, número que sigue aumentando año tras año. La mayoría de estos puestos están relacionados con la ingeniería y la instalación de los paneles. Los municipios en los que se encuentran instaladas plantas fotovoltaicas ven su población incrementada entre un 3% y un 7%, contribuyendo a disminuir la escasez poblacional del entorno rural español[13], mientras que se incrementa entorno al 2% el número de empresas de construcción y hostelería en estos municipios. El precio de la vivienda sube ligeramente debido a la mayor demanda de la zona causada por el aumento de población. Por último, los ingresos fiscales del municipio se incrementan alrededor de un 10%, y los ingresos medios de los residentes entre un 0,5% y 1%.

El uso de la fotovoltaica incluye ciertos beneficios fiscales, tanto a empresas como a particulares. Las empresas pueden beneficiarse de una deducción del impuesto de sociedades de hasta un 5% del coste de la instalación. También pueden ver su IBI reducido al 50% durante un periodo de 3 a 5 años. En cuanto a los particulares, pueden rebajar su IRPF hasta el 40% del coste de la instalación, con un máximo de 7.000€. Tanto las empresas como los particulares optan a subvenciones y ayudas del estado para invertir en las instalaciones[14]. Todos estos beneficios vienen acompañados de una mejora en la legislación de la energía solar, que en 2018 introdujo novedades como la eliminación del “impuesto al sol”, mediante el cual se gravaba a las instalaciones conectadas a la red por la energía que generaban, debido a la desincentivación que provocaba. Los trámites para la aprobación de las instalaciones también se han visto simplificados, lo que contribuye a la expansión de la fotovoltaica.

Este proyecto se centrará en el desarrollo del modelo predictivo, sin implementar una aplicación ni interfaz gráfica para su uso. Se plantearán varios potenciales modelos, y se compararán sus características para discernir cual es el más adecuado para este problema en concreto. El modelo deberá predecir la producción fotovoltaica de la planta a varios días vista. Utilizará dos datasets reales diferentes, cada uno de una planta distinta, que servirán para, por separado, entrenar al modelo. Se subirá el resultado a un repositorio remoto en GitHub para su almacenamiento y exposición.

El desarrollo del proyecto se ha dividido en cinco etapas: iniciación, planificación, ejecución, seguimiento y cierre. Durante la iniciación, se definieron los objetivos y el alcance del proyecto. En la planificación, se desarrolló el cronograma y se identificaron los recursos necesarios para la ejecución, como los datasets y la documentación del modelo. En la ejecución se desarrollaron las funcionalidades del modelo, se entrenó, probó y validó el funcionamiento del modelo predictivo. El seguimiento fue una fase que transcurrió durante todo el proyecto, encargada de revisar y corregir el progreso. Finalmente, en el cierre se recogieron las conclusiones y posibles pasos futuros que tiene el problema. A continuación, el cronograma del proyecto:

20

2. METODOLOGÍA

2.1 PASOS PREVIOS

2.1.1 POTENCIALES MODELOS

A la hora de elegir el modelo a implementar, hay que estudiar el caso para sopesar las ventajas y desventajas de cada uno, y elegir el que más se adecúe a la situación[15]. En ocasiones, puede resultar favorable la combinación de varios de ellos, aprovechando sus puntos fuertes y sustituyendo sus debilidades por otros modelos mejores en esa tarea en específico. Es clave comprender que un modelo más complejo no significa que vaya a ser mejor que uno más sencillo por el simple hecho de ser más complejo, ya que puede resultar contraproducente al no mejorar la precisión y si aumentar notoriamente la complejidad y/o el tiempo de entrenamiento. Los más importantes en este caso podrían ser los modelos multivariantes, como el LSTM o GRU, las redes convolucionales (TCN), modelos transformadores (TFT), Gradient Boosting o Random Forest Regressor.

Los modelos multivariantes han demostrado ser fiables para la predicción de consumo en el corto plazo, ya que capturan dependencias temporales y patrones no lineales. Permiten la integración de numerosas variables exógenas, como el calendario o el clima, y generan predicciones con elevada precisión. Un concepto de vital importancia es el de variable de confusión[16], el cual se da cuando la relación entre dos variables se ve notablemente afectada al introducir en la ecuación una tercera. Otro concepto resaltable es la interacción, es decir, la relación entre dos variables cuando el valor de una tercera afecta a dicha relación. A la hora de construir un modelo multivariante se plantea el problema de qué variables incluir en la ecuación, de forma que elaboremos el mejor modelo posible. Este proceso es imposible de especificar, ya que depende de si estamos ante un modelo predictivo o explicativo, del contexto y de las características del proceso. Los valores extraños son los datos con un valor anómalo, en ocasiones debido a un error al medir o introducir los datos, pero a veces son valores correctamente observados. En este tipo de modelos su presencia altera significativamente los resultados finales.

Las redes convolucionales son un tipo de red neuronal utilizada para el proceso de datos con una topología similar a una cuadrícula[17]. Las redes convolucionales pueden extraer patrones locales y recopilar dependencias a largo plazo mediante convoluciones cuando se dispone de una extensa cantidad de datos. En este contexto, las TCNs han mostrado mejoras notorias respecto a los modelos multivariantes tanto en precisión como en complejidad temporal. Las redes convolucionales modelan piezas de información secuencialmente, extrayendo información sobre los patrones. Están formadas por 5 capas, siendo estas: INPUT, capa de entrada que contiene los valores raw. CONV, que calcula la salida de las neuronas que están conectadas a la entrada, calculando un producto entre sus pesos y la región a la que están conectadas. RELU, que aplica una función de activación por elementos.

POOL, que realiza una operación de downsampling (proceso de reducción de datos disminuyendo la resolución o frecuencia de muestreo del conjunto) a lo largo de las dimensiones espaciales. Por último, la capa FC, que calcula los puntajes de clase, y cuyas neuronas estarán conectadas a todos los números en el volumen anterior.

Los modelos transformadores son un modelo de estado del arte que incorpora mecanismos de atención temporal y covariables. Estos modelos han mostrado una alta precisión en predicciones de entre 24 y 48 horas, resaltando a su vez los factores que más han influenciado esta predicción. Aunque estos modelos son relativamente nuevos en este campo, los resultados iniciales resultan prometedores. Un estudio de 2022 demuestra que los TFT no solo lograron un porcentaje de error inferior a los modelos multivariantes al predecir la producción de una planta solar, sino que mostraron la importancia de las variables meteorológicas como la irradiancia y los cambios de temperatura en la predicción productiva[18].

Entre los modelos de Gradient Boosting, el XGBoost (eXtreme Gradient Boosting) ha ganado relevancia por su capacidad de manejar entradas multivariantes y recoger interacciones complejas integrando ventanas temporales entre arquitecturas híbridas. Estudios han revelado que puede superar o complementar enfoques neuronales en precisión y velocidad de entrenamiento[19]. Para ajustar el dataset de entrenamiento del XGBoost se realiza una predicción inicial, y se crea un árbol de decisión. Se calculan los residuales en función del valor predicho. A continuación, se calcula la similitud de los datos de una hoja, y se comparan las ganancias para determinar una entidad y un umbral para el nodo. La salida del árbol será el nuevo residual para el dataset, con el que se construye un nuevo árbol. Esto se repite hasta que los residuales ya no se reducen o hasta el número de veces especificado. Cada árbol generado aprende de los árboles anteriores, y no cuenta con el mismo peso. De manera similar, LightGBM, introducido posteriormente, implementa un Gradient Boosting centrado en la escalabilidad y velocidad. Forma árboles de decisión secuencialmente para minimizar el error en la predicción de manera eficiente. Es muy común debido a su rendimiento al trabajar con conjuntos de datos extensos, haciéndolo especialmente adecuado para los problemas de pronóstico energético que involucran muchos y diferentes datos. Comparándolo con el XGBoost y otros modelos más complejos, puede conseguir una precisión aceptable con un coste computacional significativamente reducido y tiempos de entrenamiento más rápidos.

El Random Forest Regressor es un algoritmo que combina la salida de múltiples árboles de decisión para llegar a un único resultado. Destaca por su facilidad de uso y flexibilidad, ya que puede abarcar tanto problemas de regresión como problemas de clasificación[20]. Tienen tres hiperparámetros que se requiere asignar antes del entrenamiento: el tamaño del nodo, el número de árboles y la cantidad de variables muestreadas. Es un modelo interesante ya que reduce el riesgo de “overfitting” al contar con la media de árboles no relacionados reduciendo la varianza general y el error en la predicción. También, facilita la determinación de importancia a las distintas variables.

Sin embargo, cuentan con un inconveniente notable, su complejidad espacial y temporal. Debido a la cantidad de datos que maneja, requiere una gran cantidad de recursos para almacenarlos, y un tiempo considerable de entrenamiento, ya que tienen que computar datos para cada uno de los árboles de decisión.

En resumen, el estado del arte define una gran variedad de modelos efectivos para predicción energética. La elección del definitivo dependerá de las características del problema y de la cantidad y variedad de datos disponibles. Mientras que una arquitectura más compleja puede obtener resultados más precisos cuando se dispone de una cantidad de datos extensa y detallada, un método más simple con un tiempo de entrenamiento más reducido puede mejorar al complejo bajo restricciones en la cantidad de datos disponibles, ofreciendo un mejor balance entre precisión, eficiencia computacional y robustez.

2.1.2 APRENDIZAJE CONJUNTO

El aprendizaje conjunto es el proceso mediante el cual se generan múltiples modelos simples (o “weak models”) que, combinados, forman un modelo más complejo que mejora la precisión y rendimiento de los modelos simples. Uno de los objetivos de los modelos de aprendizaje conjunto es encontrar el equilibrio entre el bias y la varianza. El término bias se refiere a cuánto difiere la predicción del valor real. Es un indicador de la capacidad del modelo de asociar las relaciones entre las variables predictoras y la objetivo. La varianza, en cambio, se refiere a cuanto cambia el resultado del modelo en función de cambios en el conjunto de entrenamiento[21]. Si el modelo ha asociado debidamente los patrones entre las variables, la varianza debería ser muy reducida. En caso contrario, indicaría que el modelo está memorizando los datos de entrenamiento en vez de aprender de ellos. Dos de los tipos más populares de aprendizaje conjunto son el bagging y el boosting.

El bagging es el proceso mediante el cual múltiples modelos se entrenan utilizando diferentes secciones del conjunto de entrenamiento. Para obtener la predicción final, todos los modelos ponen en común su predicción individual, y se llega a un acuerdo para elegir cual se devuelve. En los casos de regresión suele ser la media de las predicciones individuales, mientras que en los de clasificación suele ser la clase más frecuente. Un ejemplo de modelo que use la práctica de bagging sería el Random Forest Regressor.

El boosting se diferencia del bagging en que es un proceso secuencial, en el cual se utiliza el error del modelo anterior para mejorar el siguiente, y así sucesivamente hasta obtener un resultado. De esta forma, cada modelo va aprendiendo de los anteriores. Este es el caso de modelos como el Extreme Gradient Boosting o LightGBM. Calculan la predicción de la misma forma que con bagging. Los modelos de boosting se caracterizan por tener un extenso número de hiperparámetros, siendo algunos de los más importantes el número de weak models (iteraciones), el learning rate o el tamaño máximo del árbol. La cantidad de weak models podría provocar overfitting en caso de excederse en su número.

La función del learning rate es precisamente evitar esto, ya que controla la influencia que cada weak model tiene sobre el modelo general. Cuanto menor sea su valor, mayor el número de árboles requeridos para obtener un buen resultado, pero también menor el riesgo de overfitting. En cuanto al tamaño máximo de cada árbol, se suelen usar valores entre uno y diez. Aumentar este valor incrementa notoriamente la complejidad del modelo.

La clave para que los modelos de aprendizaje conjunto consigan mejorar los modelos simples que implementan reside en que sean lo más diversos posibles, y que los errores de sus submodelos no estén relacionados. Para este caso, un modelo de boosting parece más adecuado, ya que el uso de árboles secuencialmente ayudará a que la predicción del valor de Power_gen se acerque lo máximo posible al valor real. Por lo tanto, el modelo utilizado será un Extreme Gradient Boosting (XGBoost).

2.1.3 PREPARACIÓN DEL DATASET

El primer paso a la hora de implementar un modelo de predicción es tener claro y preparado el conjunto de datos que vamos a utilizar para su entrenamiento. Este debe ser el más cercano posible a la realidad que vamos a querer predecir. El objetivo de este proyecto es la predicción del rendimiento de dos plantas fotovoltaicas en concreto: la primera, una planta instalada en el tejado de CTC en Santander, Cantabria, y la segunda, una planta flotante perteneciente a CTC en Lorca, Murcia. Para el entrenamiento del modelo usaremos datos provenientes de cada una de ellas. Es importante recalcar que no se debe bajo ningún concepto mezclar datos provenientes de ambas plantas a la hora de entrenar al modelo, ya que sus condiciones no son exactas y perjudicaría la capacidad predictiva.

En el caso del dataset de Lorca, contamos desde el principio con una gran cantidad de datos meteorológicos y de producción, pero con el inconveniente de que no eran sincrónicos, es decir, los datos meteorológicos se medían cada cinco minutos, mientras que los de producción eran variables, ya que se media en función de la velocidad del viento. Cuanto mayor era la velocidad del viento, con más frecuencia se medía. Para solucionar este problema, como el dataset simplemente copiaba el mismo valor de producción para todos los rangos de cinco minutos dentro del rango de medición de la producción, hubo que quedarse con la primera fila de cada valor de forma local, y eliminar las restantes para que no adulterasen la información. De esta forma, reducimos notablemente la cantidad de datos, pero eliminamos las grandes imprecisiones que se habrían producido en caso contrario.

En cuanto al dataset de Santander, encontramos varios problemas graves: los datos de producción no se recogieron durante la noche, y los datos meteorológicos se recogieron ligeramente desincronizados con los de producción. Para abordar el problema de la inexistente medición nocturna, la solución fue rellenar de ceros los valores de generación asociados a sus filas, ya que por la noche resulta imposible la generación de energía solar.

En cuanto a la desincronización, se optó por una asociación temporal de las filas de ambos datasets. Ya que la mayor diferencia existente entre producción y datos meteorológicos era de dos minutos, mediante un pequeño programa en Python se asoció cada fila de generación a su fila meteorológica más cercana, con un máximo de dos minutos de diferencia entre ambas y sin repetir la misma fila de valores meteorológicos para varias de producción. De esta forma, logramos sincronizar temporalmente ambos datasets para dar como resultado el conjunto de ellos.

Una vez contamos con el dataset completo y sincronizado, surgió otro problema. Analizándolo, se observaron múltiples muestras con valores anómalos e imposibles en el contexto del problema (temperaturas de 1800°, vientos de 400km/h, ...). Estos probablemente se deban a errores puntuales del sistema de medición de la planta. Nos referiremos a estos datos inverosímiles como outliers. Antes de dar por finalizada la preparación del dataset, es de vital importancia eliminar estos outliers, ya que alterarían el funcionamiento del modelo y disminuirían su precisión. El primer paso es recoger los outliers de cada columna. Para ello, hay que aplicar el rango intercuartílico[22]. Para obtenerlo, necesitamos primero calcular el percentil 25 y percentil 75. El percentil 25 es el valor por debajo del cual se encuentra el 25% de los datos, y por encima del cual se encuentra el 75% restante. El 75 percentil es lo mismo, pero al revés. La diferencia de ambos es el rango intercuartílico, valor que representa el rango en el que se encuentra el 50% central del conjunto de datos. Esto nos permitirá obtener los outliers, que serán todo aquel valor notoriamente alejado del rango intercuartílico. La fórmula booleana que determina si un valor es un outlier se define como:

$$outlier? = (valor < (percentil25 - 1.5 * IQR)) \vee (valor > (percentil75 + 1.5 * IQR))$$

Ecuación 6 - Función booleana de outlier

Esta función devuelve verdadero si el valor es un outlier, y falso en caso contrario. Una vez detectados todos los outliers, se procede a su eliminación del dataset. Esto resulta en la eliminación de una parte no demasiado extensa del dataset, lo que es muy favorable. Tras analizar el dataset de nuevo, los valores obtenidos sí que eran verosímiles y razonables, por lo que podemos considerar como correcta la eliminación de outliers, tras lo cual se procedió a la eliminación de las filas con valores vacíos (NaN) y se guardó el nuevo dataset.

Por último, observando el dataset, encontramos muestras de la variable objetivo con valor 0, pero con valores de las variables predictoras que no parecen tener sentido con un valor de Power_gen igual a 0. Estos son errores físicos del sensor de medición, y conviene corregirlos, ya que aumentará el error del modelo. Para ello, el primer paso es detectar estos errores, utilizando la media móvil de la columna Power_gen y asignando un umbral.

Si el valor es 0 y la media móvil es superior al umbral (para así descartar los valores igual a 0 verdaderos) el valor pasará a ser NaN, tras lo cual se procede a interpolar para sustituir el valor 0 inverosímil inicial por un valor razonable en el contexto.

La interpolación es un método matemático utilizado para realizar una estimación de un valor desconocido a partir de valores conocidos, mediante la implementación de un polinomio que pasa por dichos puntos[23]. Existen diversos métodos, como la interpolación lineal, la de Lagrange o la de Newton, y se aplica en diversos campos, pero esencialmente para la aproximación de valores desconocidos. En este caso usaremos la interpolación lineal, la cual dibuja una línea recta que une dos puntos y calcula los puntos intermedios en función de la pendiente de la recta. La fórmula general de la interpolación lineal es:

$$f(x) = f(x_0) + \frac{(x - x_0)}{(x_1 - x_0)} * (f(x_1) - f(x_0))$$

Ecuación 7 - Interpolación lineal

Tras la interpolación se habrá reducido enormemente el error al predecir 0, especialmente en los errores grandes. De esta forma, pasamos de un tramo como este, con varios fallos de medida seguidos:




Ilustración 6 - Datos antes de interpolar (CTC)

A este, con los datos falsamente iguales a cero interpolados con sus vecinos:




Ilustración 7 - Datos tras interpolar (CTC)

Sabemos que esta práctica es correcta ya que, observando las variables exógenas, comprobamos que no se trata de una caída natural debido a una nube o algún fenómeno ajeno a la planta, al contar con valores muy similares a sus muestras vecinas. Haber interpolado estos casos ayudará al modelo a asimilar mejor los patrones que hacen que la variable objetivo sea cero, al eliminar estos “ceros falsos” que podrían confundirlo. Además, al ser un punto medio entre sus vecinos, es más que probable que el valor real en ese momento fuese muy cercano al interpolado.

2.1.4 SIMPLE TREE

El Extreme Gradient Boosting que usaremos es un modelo basado en árboles. Dichos árboles se añaden y entrenan secuencialmente para corregir los errores cometidos por los árboles anteriores. Al estar basado en árboles, es importante conocer el funcionamiento de estos y el proceso que siguen hasta devolver la predicción. Para ello, se puede crear un modelo de tamaño reducido utilizando un solo árbol, con el fin de explicar cómo los parámetros provocan que el flujo del modelo siga una rama del árbol u otra. Un Decision Tree Regressor es un modelo de un solo árbol. Separa los datos comenzando por una condición inicial, que puede ser verdadera o falsa, y determina por que rama continuará el flujo de la predicción. Cada nodo repite este proceso hasta que se llega a los nodos hoja del árbol, que devuelven la predicción final. Dependiendo de la profundidad del árbol, la predicción podrá ser más o menos correcta, ya que, a mayor profundidad, mayor número de condiciones que ha tenido que cumplir el contexto para llegar hasta un punto determinado[24]. Las condiciones planteadas por los nodos más cercanos a la raíz suelen tener que ver con las variables más importantes en la predicción, ya que son las que más condicionan el resultado cuando su valor varía. Cercanas a los nodos hojas, están las variables menos importantes, ya que en líneas generales no cambian mucho el resultado final:




Ilustración 8 - SimpleTree

Observamos como el nodo raíz plantea la condición de si el valor de lag_1 es menor o igual a 172.5, dividiendo en ramas sus posibles respuestas. Este proceso se repite con otras preguntas hasta alcanzar los nodos hojas con la solución final a la predicción. Este modelo de un solo árbol obtiene resultados mucho peores a los que veremos posteriormente en el Extreme Gradient Boosting, lo cual es lógico debido a la sola presencia de un árbol en comparación con los múltiples árboles del Gradient Boosting.

En cuanto a las métricas generales, estos fueron los resultados:

MAE	58.4135
MSE	5405.5473
RMSE	73.5224
R ²	0.7389

Tabla 3 - Métricas SimpleTree

Se observan resultados pobres, con un error medio elevado para el contexto del problema y un coeficiente de determinación mediocre. En cuanto a la predicción a 24 horas vista:




Ilustración 9 - Predicción 24h SimpleTree

Y 48 horas vista:




Ilustración 10 - Predicción 48h SimpleTree

En estas gráficas se apreciará claramente la mejora al utilizar más de un árbol para la predicción. Destaca que con un solo árbol nunca llega a predecir cero, aunque si posee aproximadamente la forma de la evolución de la variable objetivo, con sus subidas y bajadas a lo largo del día.

2.1.5 HERRAMIENTAS

El modelo se desarrollará en Python, haciendo uso de diversas herramientas y librerías. Se hará uso de Anaconda, una plataforma de código abierto especializada en trabajos relativos a la ciencia de datos y la inteligencia artificial en Python[25]. Su uso facilita enormemente el desarrollo al contar con cientos de librerías y recursos previamente instalados que agilizan todo el proceso. A su vez, se utilizará Jupyter Notebook, un editor de código para hacer el proceso más visual, organizado e intuitivo[26].

En cuanto a las librerías, sklearn es una librería de aprendizaje automático de código abierto, que incluye funciones para implementar y/o entrenar modelos como gradient boosting, SVM, k-means, entre otros. También incluye funciones para visualizar las métricas del modelo, como la media de error absoluto, el coeficiente de determinación, el error cuadrático medio, ... Que serán cruciales para medir la precisión del modelo. A su vez, utilizaremos la librería xgboost para hacer uso del XGBRegressor que proporciona, el cual incluye lo necesario para crear y entrenar un extreme gradient boosting, además de funciones interesantes, como `feature_importances_`, que valora las variables en función de su influencia en el resultado de la predicción. Para la visualización gráfica de los datos se hará uso de la librería seaborn, la cual está construida con matplotlib e integrada en pandas, y especializada en la visualización de datos estadísticos.

Ya que el problema es un modelo de predicción basado en series temporales, la librería Skforecast proporciona herramientas clave para esta tarea, como el ForecasterRecursive, que permite implementar un modelo de regresión de forma recursiva incluyendo como parámetros del modelo las muestras anteriores deseadas de la variable objetivo, es decir, los “lags”[27]. A su vez cuenta con los “Rolling Features”, los cuales son valores, como la media, el máximo o el mínimo, que cuentan con un tamaño de ventana determinado y van variando su valor. Es decir, cada muestra contará con tres nuevas columnas, la media, máximo y mínimo de los 20 anteriores valores, por ejemplo. También cuenta con la función GridSearchForecaster, que nos permitirá obtener los valores óptimos para los parámetros del modelo implementado, maximizando así su precisión y coeficiente de determinación. La librería Shap será interesante para descomponer las predicciones del modelo para mostrar cuánto contribuyó cada característica a una decisión específica.

Usaremos el DecisionTreeRegressor de sklearn para explicar el funcionamiento de los árboles de decisión e ilustrar el ejemplo que nos ocupa y sus condiciones de separación en ramas, con las variables que determinan dichas condiciones.

2.2 MODELADO

Las series temporales son sucesiones de datos ordenados cronológicamente, espaciados a intervalos iguales o desiguales. El proceso de forecasting consiste en predecir el valor futuro de una serie temporal, pudiendo emplear su comportamiento pasado, de forma autorregresiva, y/o variables externas[28]. Antes de comenzar a modelar, es clave identificar y diferenciar las variables exógenas y endógenas del modelo. Las variables endógenas son aquellas que provienen del propio modelo, mientras que las exógenas son ajenas a este, pero se implementan para su beneficio predictivo. Las variables endógenas principales en este caso serán los lags, es decir, los valores anteriores de la variable objetivo, que permitirán tener en cuenta su progresión para determinar cómo evolucionará esa tendencia. De esta manera, se incluyen como columnas, junto con el resto de las variables, por ejemplo, los tres valores anteriores, el valor de 24 horas antes, el de una semana antes, ... También, resulta muy beneficiosa la inclusión de “window features”, los cuales son valores obtenidos a partir de las muestras anteriores de la variable.

Por ejemplo, es común encontrar la media, el máximo o el mínimo de los diez, quince o veinte valores anteriores, de forma que el modelo tenga en cuenta la evolución de la variable y/o el rango de máximos y mínimos que ha tomado recientemente, contribuyendo a la formación de patrones predictivos más precisos. Las variables exógenas, en cambio, son aquellas ajenas al modelo, pero que afectan a la variable objetivo[29]. Es muy beneficioso proporcionárselas al modelo a la hora de predecir, ya que así el propio modelo no deberá “inventárselas”.

En el caso que nos ocupa, si queremos predecir la potencia fotovoltaica que vamos a generar mañana, la predicción será más precisa si le proporcionamos al modelo los datos meteorológicos esperados (temperatura, irradiancia, ...) de mañana, ya que, en caso contrario, deberá asignarle unos valores razonables y después predecir la potencia.

Los modelos de series temporales se diferencian de la regresión clásica en que el paso del tiempo y la tendencia del valor objetivo juegan un papel protagonista en la predicción, pero no dejan de ser implementaciones de modelos de regresión, como gradient boosting o Random Forest Regressor.

A la hora de entrenar el modelo, puede resultar interesante dividir la variable temporal (fecha) en varias variables (mes, día, hora), ya que así podemos ver cómo afecta individualmente cada parámetro a la producción. La lógica indica que, teniendo en cuenta la salida y la puesta del sol, el momento de mayor producción debería situarse en torno al mediodía solar y el de menor producción, es decir, cero, durante la noche. En este caso, la variable “hora” implementada a partir de “fecha” sería bastante relevante para el futuro valor de Power_gen. De igual manera, es lógico pensar que la producción se incrementará en verano y disminuirá en invierno, por lo que también se espera que la variable “mes” tenga importancia predictiva. En contrario, “día” no debería tener una relevancia significativa.

En cuanto a los lags, en este caso particular no es conveniente utilizar lags notablemente alejados en el tiempo del valor que intentamos predecir, ya que factores imprevisibles, como una nube, que afectan directamente al valor de potencia generada, no se tienen en cuenta, y la evolución de un valor a otro de la variable objetivo no es representativa de la realidad. Es por eso por lo que los valores más relevantes son los inmediatamente anteriores a la muestra objetivo, en este caso utilizaremos las siete muestras anteriores, desde unos treinta y cinco minutos antes hasta cinco minutos antes.

2.2.1 ESCALADO

Se da el caso de que los datos del dataset tienen distintas escalas, lo que puede afectar al rendimiento del modelo, por lo que es una buena práctica escalar los datos. Es importante que este escalado sea posterior en el tiempo a la separación del conjunto de datos en conjuntos de entrenamiento y test, ya que en caso de hacerlo antes estaríamos filtrando información sobre el entrenamiento al conjunto de test, lo que haría que las métricas de predicción fuesen irrealmente buenas, pero que se desplomasen en cuanto sometieses al modelo a datos ajenos al conjunto de test. Esta mala práctica se conoce como “Data Leaking”, y al separar el conjunto en entrenamiento y test antes de escalar eliminamos la posibilidad de que se produzca[30].

El escalamiento, de forma sencilla, hace que todas las variables de nuestro dataset tengan el mismo rango de valores posibles. Estos pueden ser, por ejemplo, de cero a uno, lo que se conoce como la normalización de los datos y es muy común en este tipo de problemas. También, podría ser entre cero y la desviación estándar de uno, lo que se conoce como estandarización[31].

Para escalar los datos en este caso usaremos un MinMaxScaler. Este método obtiene el parámetro máximo y mínimo de cada variable, y escala los datos de la columna siguiendo la siguiente fórmula:

$$x_{iesc} = \frac{x_i - x_{imin}}{x_{imax} - x_{imin}}$$

Ecuación 8 - Escalamiento con MinMaxScaler

Donde x_i se refiere a cada columna del conjunto de datos, x_{imin} y x_{imax} el valor mínimo y máximo de la columna, y x_{iesc} el valor escalado entre cero y uno.

Resulta interesante conocer el grado de correlación entre las variables del dataset, ya que proporciona información útil a la hora de entrenar un modelo. Por ejemplo, podemos descubrir como la variable objetivo, se ve influida por el resto de las variables, diferenciando las más importantes de las irrelevantes:




Ilustración 11 - Mapa de calor (CTC)




Ilustración 12 - Mapa de calor (Lorca)

Podemos observar que los grados de correlación tienen sentido físico. Recordemos que una correlación positiva significa que ambas variables son directamente proporcionales, es decir, si se incrementa una, se incrementa la otra. Al contrario, una correlación negativa indica que las variables implicadas son inversamente proporcionales, cuando una crece, decrece la otra. Valores cercanos a uno, como el de solarRad y Power_gen, indican una gran influencia entre estas variables, que crecen conjuntamente. En caso contrario, el valor de aproximadamente -0.4 entre humedad y Power_gen indica que, a mayor humedad, menos potencia generada y viceversa. Resulta llamativo que, en el caso de Lorca, la variable rain es completamente irrelevante. Esto es debido a que ninguna fila con un valor distinto de 0 ha sobrevivido al proceso de criba, entre la eliminación de outliers y filas con valores NaN. Debido a esto, podríamos obviarla a la hora del entrenamiento del modelo.

2.2.2 ENTRENAMIENTO

A continuación, se entrenó un modelo forecaster recursivo utilizando un Xgboost con los siguientes parámetros[32]. Learning_rate (eta), representa la reducción en el tamaño de cada paso para evitar el overfitting del modelo. Tras cada paso, obtenemos los pesos de las nuevas variables y eta reduce el peso de las variables para hacer el proceso más conservador. Max_depth, indica la profundidad máxima del árbol, por lo que aumentar este valor hará el modelo más complejo y propenso a sobreajuste. El XGBoost consume una gran cantidad de memoria según se aumenta este valor, por lo que hay que tratar de encontrar el equilibrio entre complejidad suficiente y tiempo de entrenamiento razonable. N_estimators controla el número de árboles que se implementarán en el modelo, por lo que, junto con max_depth, es el parámetro que más aumentará la complejidad y, a su vez, el tiempo de entrenamiento. Un valor alto hará el modelo más preciso. Subsample determina el ratio de muestreo de los valores de entrenamiento. El valor que tome indicará al XGBoost la cantidad de datos que debe muestrear aleatoriamente antes de comenzar a implementar los árboles, lo que contribuirá a evitar el sobreajuste. Este proceso se hace una vez por cada iteración del modelo. Base_score representa la predicción inicial para todos los valores, si toma, por ejemplo, un valor de 0.0, hará que todas las predicciones sean inicialmente 0.0, y posteriormente se modifiquen en el proceso de predicción. Precisamente el valor de 0.0 puede ayudar al modelo en los casos en que deba predecir cero, ya que en caso contrario sería posible que nunca llegase a predecir exactamente cero, sino un valor extremadamente cercano. Reg_alpha representa el término de regularización sobre los pesos, de forma que aumentarlo provocará que el modelo sea más conservativo. Colsample_by_tree representa la cantidad de columnas que se toman al construir cada árbol.

Para obtener los valores adecuados de los parámetros del xgboost, se optó por su búsqueda mediante un GridSearchCV[33]. GridSearchCV es una técnica de validación cruzada utilizada para obtener la mejor combinación posible de parámetros.

Para ello, hay que indicarle una cuadrícula de parámetros con diferentes valores, de forma que GridSearchCV pruebe a combinarlos de todas las formas posibles y nos devuelva aquella que haya obtenido un mejor resultado en la métrica que le hayamos indicado (accuracy, mean_absolute_error, neg_root_mean_squared_error, ...). Tras entrenar el modelo ajustando estos parámetros, se calculó la importancia de cada variable en la predicción de la potencia generada. Podemos observar un sentido físico, ya que variables como la irradiancia o la hora del día cuentan con una gran relevancia, junto con la muestra inmediatamente anterior, mientras que otras como la presión o la velocidad del viento presentan una influencia superficial:

Variable	Importancia
Lag_1	0.639488
Lag_2	0.158001
solarRad	0.054222
Hour	0.032133
Lag_3	0.013434
Month	0.012951
Roll_min_20	0.009755
Lag_6	0.008500
Lag_7	0.008080
Roll_max_20	0.007707
Resto de variables	0.055729

Tabla 4 - Importancia de variables (CTC)

Variable	Importancia
solarRad	0.600340
Lag_1	0.111982
Lag_2	0.038900
Hour	0.033658
Roll_max_10	0.033024
Month	0.032332
Roll_mean_10	0.020661
Roll_min_10	0.019207
Temperature	0.018804
Minute	0.016008
Resto de variables	0.075084

Tabla 5 - Importancia de variables (Lorca)

2.2.3 OVERFITTING

Es importante comprobar la no presencia de sobreajuste, u overfitting, en el modelo. En caso de tener un modelo sobreajustado, este memorizará los datos de entrenamiento en vez de aprender patrones, lo que provocará que al exponerlo a datos ajenos al conjunto de entrenamiento la precisión predictiva brille por su ausencia[34]. Una forma de comprobar la existencia de sobreajuste gráficamente es observar la progresión del error según el número de iteraciones. Si el error aumenta considerablemente en el conjunto de validación mientras que el de entrenamiento se mantiene bajando, estamos ante un modelo sobreajustado.




Ilustración 13 - Detección de overfitting sin early stop

En la gráfica anterior se puede observar como el error en la métrica root mean squared error disminuye conjuntamente en el conjunto de entrenamiento y validación, hasta que llega el momento en que se cruzan, a partir de cuando el error en validación se estabiliza y el de entrenamiento sigue bajando. La forma general de la gráfica nos indica que no estamos ante un caso de sobreajuste, ya que el modelo ha aprendido patrones predictivos que aplica correctamente al conjunto de validación. En este caso, no se ha aplicado un `early_stopping_rounds` a la hora de entrenar, por lo que el modelo seguirá hasta que acabe todos los árboles presentes. En caso de darle un valor a este parámetro, el modelo se detendría cuando pasasen las iteraciones indicadas a partir de que el error deja de disminuir. Si, por ejemplo, se le asigna el valor 50, el modelo se detendrá en el momento en que no se haya mejorado el error en 50 iteraciones. Haciendo esto, obtenemos que a partir de la iteración 400 el error en el conjunto de validación no mejora:




Ilustración 14 - Detección de overfitting con early stop

Hay que asegurarse de que la parada no se realice demasiado pronto, ya que excluiría características importantes y provocaría lo contrario a sobreajuste, el infraajuste o underfitting. El infraajuste se da cuando el tiempo de entrenamiento no ha sido suficiente o cuando las variables de entrada no son lo suficientemente significativas como para determinar unos patrones entre las variables de entrada y las de objetivo.

2.3 PREDICCIÓN

2.3.1 REPRESENTACIÓN GRÁFICA

Tras el entrenamiento, se puso a prueba el modelo prediciendo los valores del conjunto de test extraído del dataset original. Gráficamente, estos fueron los resultados:




Ilustración 15 - Predicciones CTC




Ilustración 16 - Predicciones Lorca

Podemos observar cómo, en líneas generales, el modelo acierta en la evolución de la variable, pero, sobre todo en el caso del CTC, no llega a predecir con precisión los valores altos. Esto es debido principalmente a la escasez de datos con estos valores tan elevados.

Para mejorar esta situación, podemos añadir una columna extra al conjunto de datos, que le indique al modelo hasta donde podría llegar a ascender la predicción, actuando como un “techo de la variable”. Para calcular esta irradiancia ideal, se asume una forma parabólica de la irradiancia real, es decir, que el punto de mayor irradiancia se encuentre en el centro, en el llamado mediodía solar. Se calculan los minutos transcurridos desde medianoche para cada muestra, con el objetivo de normalizar la diferencia respecto al mediodía solar:

$$x = (\text{transcurridos} - \text{mediodia})/(\text{mins_dia}/2)$$
$$\text{irr_ideal} = 1 - x^2$$

Ecuación 9 - Normalización diferencia a mediodía

A un nivel más bajo, la evolución de la predicción en 24 horas:




Ilustración 17 - Predicción 24h CTC

Y en 48 horas:




Ilustración 18 - Predicción 48h CTC

En líneas generales, observamos que el modelo tiene la forma adecuada, prediciendo correctamente las subidas y bajadas de producción que se generan a lo largo del día. Si bien persiste el problema de que no termina de ascender hasta los valores máximos, los resultados son mejores que antes de la irradiancia ideal. También comprobamos que la mejora respecto al modelo de un solo árbol ha sido muy significativa, ya que en este caso sí que predice cero y ha asimilado patrones que mejoran notablemente la predicción de las subidas y bajadas de generación a lo largo del día.

Para observar el resultado general del modelo en la predicción, podemos comparar gráficamente cada muestra predicha con la real. Aquí, se observará claramente el problema que tratamos con anterioridad mediante la interpolación de los datos:




Ilustración 19 - Comparación predicción realidad antes de interpolación (CTC)




Ilustración 20 - Comparación predicción realidad tras interpolación (CTC)

Observamos como antes había una gran cantidad de errores en el valor cero, algunos superiores a 400. También, se aprecia un pequeño espacio entre el cero y el resto de los valores, concretamente hasta el treinta y nueve. Esto se debe a que en el conjunto de datos no hay ninguna muestra con un valor dentro de este rango, ya que el sensor físico no comienza a registrar los valores hasta que superen el umbral de treinta y nueve. Los resultados obtenidos son positivos, ya que el grueso de los valores predichos se encuentra sobre la línea de igualdad (discontinua roja en la ilustración), y la forma de la gráfica es ascendente. Volvemos a apreciar el error en los valores grandes, ya que los puntos en esa zona de la gráfica cuentan con una dispersión significativamente superior al rango (0,300]. En el caso de Lorca, esto es diferente:




Ilustración 21 - Comparativa predicción realidad (Lorca)

Salta a la vista que la cantidad de datos en este conjunto de datos es inmensamente inferior al de CTC. Esto lastra el rendimiento predictivo de este modelo, como podemos observar en esta gráfica o en métricas como el coeficiente de determinación (0.84 frente al 0.92 del CTC).

2.3.2 MÉTRICAS DE PREDICCIÓN

Tras la adición de la irradiancia ideal, se repite la predicción, y observamos una ligera, aunque presente mejora en las métricas de predicción. Hay que tener en cuenta que las unidades en el de CTC son vatios, mientras que en el de Lorca son kilovatios:

MAE	17.0592
MSE	1704.9633
RMSE	41.2912
R ²	0.9176

Tabla 6 - Métricas antes de irr_ideal (CTC)

MAE	16.5215 (-3,15%)
MSE	1631.2590 (-4,32%)
RMSE	40.3888 (-2,18%)
R ²	0.9212 (+0,39%)

Tabla 7 - Métricas después de irr_ideal (CTC)

MAE	1.8600
MSE	7.9893
RMSE	2.8265
R ²	0.8354

Tabla 8 - Métricas antes de irr_ideal (Lorca)

MAE	1.7726 (-4,69%)
MSE	7.6645 (-4,06%)
RMSE	2.7685 (-2,05%)
R ²	0.8421 (+0,8%)

Tabla 9 - Métricas después de irr_ideal (Lorca)

El MAE (Mean Absolute Error) mide la diferencia absoluta media entre los valores predichos y los reales. Indica cuanto se aleja la predicción de la realidad, sin importar si un error es grande o pequeño. Se calcula de la siguiente forma:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_{real,i} - y_{prediccion,i}|$$

Ecuación 10 - Mean Absolute Error

El MSE (Mean Squared Error) es como el MAE, pero elevando al cuadrado la diferencia de las predicciones. De esta forma se castigará más severamente los errores grandes que los pequeños:

$$MSE = \frac{1}{n} \sum_{i=1}^n (|y_{real,i} - y_{prediccion,i}|)^2$$

Ecuación 11 - Mean Squared Error

El RMSE (Root Mean Squared Error) es la raíz cuadrada del MSE. Indica cuánto error debemos esperar de las predicciones en término medio. Es especialmente útil cuando el objetivo es minimizar las magnitudes de error e interpretar el rendimiento del modelo en el mundo real:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (|y_{real,i} - y_{prediccion,i}|)^2}$$

Ecuación 12 - Root Mean Squared Error

El R^2 (Coeficiente de determinación) explica qué proporción de la varianza de la variable es explicada por el modelo. Está dentro del rango $[0,1]$. Un valor cercano a 1 indica que el modelo explica prácticamente la totalidad de la varianza, mientras que un valor cercano a 0 significa lo contrario. Un valor de 0 implicaría que la predicción del modelo no mejora a calcular la media en todos los casos:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Ecuación 13 - Coeficiente de determinación

2.3.3 PREDICCIÓN CRUZADA

Hemos observado las métricas predictivas de cada modelo en su entorno específico, sobre unos datos que se suponen similares a los usados en el entrenamiento. A continuación, comprobaremos qué sucede cuando se trata de predecir los datos de un lugar con el modelo de otro. Como la diferencia entre las condiciones de Santander y Lorca son tan abruptas, se espera que los resultados de predecir los datos utilizando el modelo contrario sean desastrosos. Esto es debido a que cada modelo habrá asociado patrones en función de los datos y el contexto de cada problema individual. Por ejemplo, en el caso de Lorca, puede haber aprendido: “Cuando la temperatura es superior a 32°, el Power_gen será X”, pero en los datos de Santander no hay casos con esa temperatura. También, habrá casos con una lluvia elevada que el modelo de Lorca no sepa interpretar, ya que en su entrenamiento todos los valores de lluvia eran cero. De la misma manera, pasará lo mismo al predecir Lorca con el modelo de Santander, en los casos de temperaturas muy altas fallará estrepitosamente, ya que no sabe cómo deberían afectar estas altas temperaturas a la predicción. En resumen, los modelos estarían aplicando reglas especializadas en su problema individual a otro conjunto de datos con rangos de valores que distan notablemente de los aprendidos. En conclusión, estos fueron los resultados obtenidos:

MAE	360.5806
MSE	141587.9633
RMSE	376.2818
R^2	-3364.1871

Tabla 10 - Predicción datos Lorca con modelo CTC

MAE	85.8118
MSE	29948.4738
RMSE	173.0563
R^2	-0.2140

Tabla 11 - Predicción datos CTC con modelo Lorca

Se observa que, en ambos casos, el coeficiente de determinación es negativo, lo que indica que el modelo predice peor que la media en todos los casos, ya que introduce error a la predicción. El resto de las métricas son absurdamente malas, lo que en efecto confirma la imposibilidad de predecir correctamente unos datos ajenos al contexto de entrenamiento del modelo.

2.4 APLICACIONES PRÁCTICAS

El desarrollo de un modelo de predicción no tiene sentido sin una aplicación práctica. En este caso, como se mencionó con anterioridad, el objetivo es el control energético de una planta sujeta a la ley de la inyección cero. Gracias al modelo, se podrá aproximar la generación de la planta y, de esta manera, administrar el consumo de forma que se ajuste a la producción con la mayor exactitud posible. Esto será beneficioso en los casos en los que haya que llevar a cabo un proceso productivo altamente demandante energéticamente, ya que el técnico responsable dispondrá de datos para decidir cuándo llevarlo a cabo, si debe esperar porque próximamente dispondrá de mayor energía o si deber hacerlo ya porque se espera una baja producción en las próximas horas. Por ejemplo, puede resultar interesante saber si habrá una mayor producción por la mañana o por la tarde. Calculando la producción esperada de la mañana y la tarde de los próximos días será posible determinar en qué día y rango horario será más adecuado llevar a cabo un proceso energéticamente demandante:




Ilustración 22 - Predicción mañana/tarde (Lorca)




Ilustración 23 - Predicción mañana/tarde (CTC)

Se observa que, en el caso de Lorca, claramente es más adecuado planificar el mayor consumo por la tarde, que es cuando se espera una mayor producción normalmente. En el caso de CTC varía más, debido a las grandes diferencias meteorológicas entre Lorca y Santander este resultado era esperable.

También se podría necesitar la predicción de unos días en concreto, como por ejemplo una producción urgente que se debe llevar a cabo en las próximas 48 horas:




Ilustración 24 - Media mañana/tarde (CTC)




Ilustración 25 - Media mañana/tarde (Lorca)

También, saber cuánto vas a producir es clave para un correcto uso de las baterías, sabiendo cuando debes cargar y cuando reservar energía en estas porque no se espera una gran producción próximamente. De esta forma podrás suavizar la curva de potencia y evitar picos en la red. De la misma manera, puedes saber si la escala de tu instalación es adecuada, si deberías instalar más paneles porque no estás aprovechando toda la energía que podrías, o, por el contrario, si deberías retirar paneles porque la energía generada no compensará la inversión inicial de la instalación. Se podrán hacer estimaciones del retorno de la inversión que contribuyan al bienestar económico de la entidad propietaria de la instalación.

La predicción también puede servir como referencia de lo que, en las condiciones del momento, debería generar la instalación. De esta forma, si el técnico observa que la producción es visiblemente inferior a la predicha, puede comprobar si existe suciedad o roturas en los paneles, ahorrándose así tareas de mantenimiento constantes, ya que comprueba fácilmente si hay algo que no funciona como debería.

3. PASOS FUTUROS

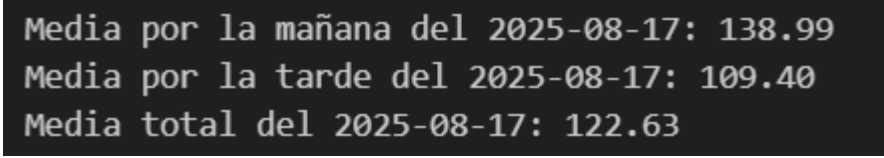
Los modelos de predicción de series temporales pueden tener una complejidad muy superior al desarrollado en este proyecto, por lo que es interesante conocer y estudiar posibles líneas de trabajo futuras que se podrían desarrollar para mejorar la precisión y la utilidad del modelo.

Por supuesto, sería interesante la implementación de más variables meteorológicas, como la nubosidad o la hora de salida y puesta del sol, o variables del entorno, como el polvo o la orientación, de las que por desgracia no hemos podido disponer en este caso. Se esperaría que su implementación mejorase ligeramente la precisión de la predicción, ya que podría generar un mayor número de patrones que aprender.

Por otro lado, la implementación del forecaster basado en otro tipo de modelo que no sea un Extreme Gradient Boosting expondría las diferencias respecto a este y serviría para determinar si la elección del modelo fue óptima. Podrían utilizarse alguno de los modelos descritos como potenciales anteriormente en este documento, como las redes convolucionales, los modelos transformadores o un Random Forest Regressor. Sin embargo, se espera que el mayor rendimiento sea el proveniente del actual modelo, el Extreme Gradient Boosting, ya que, por lo general, suele ser el óptimo para este tipo de problemas. Otro enfoque podría ser sacrificar algo de precisión a cambio de un modelo menos complejo y con un coste inferior temporalmente y/o espacialmente, contexto en el cual sería favorable un modelo más simple como el LightGBM, que, al igual que el Extreme Gradient Boosting, es un modelo basado en árboles de decisión, pero que destaca por su velocidad y eficiencia.

Uno de los pasos futuros más importantes a tomar sería la implementación del modelo en un Energy Management System (EMS) que, obteniendo las variables meteorológicas, devolviese la predicción esperada. Este EMS podría vincularse a un organismo como la AEMET y utilizar su información para generar predicciones productivas en tiempo real. Debería realizar un proceso de consulta a la API de la AEMET, descargar los datos que procedan, procesarlos para convertirlos al formato utilizado por el modelo y entregarlos como entrada al modelo para que devuelva la generación esperada. Podría ejecutarse con un script programado de forma que, con una frecuencia determinada, por ejemplo, diariamente, o cada vez que la AEMET actualice los datos, el modelo repita el proceso y mantenga actualizado al operario de la situación energética esperada de la planta. Utilizando este proceso, podría integrarse con una interfaz en la que se refleje cada departamento y/o tarea junto con su consumo. Una interesante ampliación del problema sería elaborar un sistema que obtenga la predicción de la generación y automáticamente informe al operario de la manera óptima de distribuir la carga entre toda la maquinaria y procesos. Por ejemplo, una posible salida del modelo sería: “Máquina 1: Mañana, Máquina 2: Tarde, Máquina 3: Tarde, ...”.

La implementación de una interfaz gráfica facilitaría el uso del modelo, especialmente en personal ajeno al contexto del aprendizaje automático. Una interfaz que contase con lo descrito previamente, junto con una entrada para consultas específicas, tendría un impacto muy positivo. Por ejemplo, de la siguiente forma:



```
Media por la mañana del 2025-08-17: 138.99
Media por la tarde del 2025-08-17: 109.40
Media total del 2025-08-17: 122.63
```

Ilustración 26 - Ejemplo consulta de media

4. CONCLUSIONES

En resumen, en este trabajo hemos observado la progresión de un proyecto de predicción de la producción fotovoltaica de dos plantas distintas, desde la etapa de preprocesamiento, hasta la etapa de predicción, pasando por la de entrenamiento. El correcto procesamiento de los conjuntos de datos ha sido clave de cara a obtener un resultado favorable, eliminando outliers, valores nulos e interpolando en los casos que procediera. La separación en datos de entrenamiento y test antes de escalar también fue determinante, al evitar el data leaking que habría provocado unas métricas excelentes pero irreales, y perjudicando al modelo a la hora de predecir nuevos datos. Se ha observado que el XGBoost ha sido una elección robusta y favorable para el contexto del problema. La librería de Skforecast ha resultado altamente efectiva para implementar series temporales, ofreciendo todas las herramientas necesarias para configurar un modelo de este tipo, con las dificultades que ello implica. La inclusión de lags y Rolling features, además de las variables exógenas, ha tenido un impacto significativo y ha mejorado notablemente el rendimiento, prueba de que su uso es conveniente en las series temporales.

El modelo desarrollado propone una solución al problema planteado en la introducción de este documento, la inyección cero. De esta manera, se podrá evitar producir excedentes en la energía generada mediante una correcta gestión del consumo y/o la planificación óptima de las baterías, así como para hacer que el tamaño de la instalación sea el adecuado para un correcto retorno de la inversión.

Los resultados obtenidos han sido muy favorables, aunque es una pena el inconveniente con el conjunto de datos de Lorca, ya que habría sido muy interesante poder compararlo con el de Santander en un contexto de igualdad en la cantidad de datos. Aún con este inconveniente, ha quedado clara la diferencia de las condiciones meteorológicas entre ambas ciudades y como estas afectan al entrenamiento del modelo, reflejando los diferentes patrones y rangos que ambos modelos han asimilado. También, se ha demostrado la imposibilidad de obtener una predicción adecuada cuando el contexto de los datos a predecir es distinto al del modelo. Se podría hacer afrontado el problema desde múltiples puntos de vista diferentes, se optó por los presentes en este documento ya que se consideraron los más adecuados, pero esto no quiere decir que las soluciones planteadas sean únicas.

Desde mi punto de vista, se ha demostrado la importancia e impacto que puede tener la inteligencia artificial en el campo de la energía renovable, ayudando no solo a reducir las emisiones de CO₂, sino también a reducir el gasto económico en energía. Considero que implementar y utilizar un modelo de este tipo ofrece una ventaja competitiva en el sector, y facilita el trabajo diario del personal de la planta. Actualmente es una práctica en auge, y no tengo dudas de que es un tipo de tecnología que ha venido para quedarse en el sector de la energía renovable. Los modelos desarrollados están disponibles en el siguiente [repositorio público de GitHub](#).

REFERENCIAS

- [1] M. A. Castán-Lascorz, B. D. Mselle, L. L. Zabaleta, M. León, y J. Arroyo, «Energy Flexibility Optimization in Industry: A Hybrid Approach with Synthetic Data Evaluation», en *2025 IEEE International Conference on Engineering, Technology, and Innovation (ICE/ITMC)*, Valencia, Spain: IEEE, jun. 2025, pp. 1-10. doi: 10.1109/ICE/ITMC65658.2025.11106527.
- [2] «Energía solar fotovoltaica y su contribución | ACCIONA | Business as unusual». Accedido: 3 de noviembre de 2025. [En línea]. Disponible en: <https://www.acciona.com/es/energias-renovables/energia-solar/fotovoltaica>
- [3] «Guía completa: Cómo evaluar el rendimiento de las placas solares de forma efectiva - Soletec». Accedido: 4 de noviembre de 2025. [En línea]. Disponible en: <https://soletec.es/como-evaluar-el-rendimiento-de-placas-solares/>
- [4] «Energía solar fotovoltaica: potencia instalada en España 2010-2024», Statista. Accedido: 30 de octubre de 2025. [En línea]. Disponible en: <https://es.statista.com/estadisticas/1004387/potencia-solar-fotovoltaica-instalada-en-espana/>
- [5] «Solar fotovoltaica (Sol)(Generación)», Informes del sistema. Accedido: 30 de octubre de 2025. [En línea]. Disponible en: <https://www.sistemaelectrico-ree.es/es/informe-de-energias-renovables/sol/generacion/solar-fotovoltaica-solgeneracion>
- [6] UNEF, «El sector fotovoltaico se estabilizó en 2024 pero urge cambios para su crecimiento, como el necesario avance de la electrificación», UNEF. Accedido: 3 de noviembre de 2025. [En línea]. Disponible en: <https://www.unef.es/es/comunicacion/comunicacion-post/>
- [7] audema, «Situación actual de la energía fotovoltaica en España - Audema». Accedido: 3 de noviembre de 2025. [En línea]. Disponible en: <https://www.audema.com/situacion-actual-de-la-energia-fotovoltaica-en-espana/>
- [8] Energía, «[Fotovoltaica] Impacto ambiental • Ecologistas en Acción», Ecologistas en Acción. Accedido: 10 de noviembre de 2025. [En línea]. Disponible en: <https://www.ecologistasenaccion.org/10057/fotovoltaica-impacto-ambiental/>
- [9] Chombi, «¿Cuál es el Impacto Medioambiental de los Paneles Fotovoltaicos?», Novaluz. Accedido: 31 de octubre de 2025. [En línea]. Disponible en: <https://novaluz.es/impacto-ambiental-de-los-paneles-fotovoltaicos/>
- [10] lafabricasolar_vmphyw, «El impacto de la energía solar fotovoltaica en la economía española», La Fábrica Solar. Accedido: 4 de noviembre de 2025. [En línea]. Disponible en: <https://www.lafabricasolar.com/impacto-energia-solar-fotovoltaica/>
- [11] lafabricasolar_vmphyw, «El impacto de la energía solar fotovoltaica en la economía española», La Fábrica Solar. Accedido: 30 de octubre de 2025. [En línea]. Disponible en: <https://www.lafabricasolar.com/impacto-energia-solar-fotovoltaica/>
- [12] admin, «Revalorización de Viviendas con Placas Solares en España», PULSEN ENERGY - Instalación de Placas Solares y Cargadores Eléctricos. Accedido: 4 de noviembre de 2025. [En línea]. Disponible en: <https://pulsenenergy.com/revalorizacion-de-viviendas-con-placas-solares-en-espana/>
- [13] E. estudio «Impacto socioeconómico de las inversiones en energía solar fotovoltaica», realizado por equipos de investigación de la U. C. I. de M. y la U. Complutense, R. Q. L. I. D. P. S. C. a D. E. E. Local, A. Población, y estimular el tejido empresarial y aumentar los ingresos municipales P. S. Molina, «Un estudio

- cuantifica los beneficios económicos y sociales de la fotovoltaica en el medio rural español», pv magazine España. Accedido: 3 de noviembre de 2025. [En línea]. Disponible en: <https://www.pv-magazine.es/2025/05/28/un-estudio-cuantifica-los-beneficios-economicos-y-sociales-de-la-fotovoltaica-en-el-medio-rural-espanol/>
- [14] Grafico38, «▷ Los beneficios fiscales de la energía solar en 2024», ClimaBeiro. Accedido: 4 de noviembre de 2025. [En línea]. Disponible en: <https://climabeiro.es/blog/beneficios-fiscales-energia-solar/>
- [15] K. vutukuri, «7. Classical Machine Learning vs Neural Approaches», Medium. Accedido: 6 de noviembre de 2025. [En línea]. Disponible en: <https://medium.com/@kiranvutukuri/7-classical-machine-learning-vs-neural-approaches-9316b3804af5>
- [16] JesusGarciaFernandez, «Construcción de modelos de regresión multivariantes», SEHLELHA. Accedido: 11 de noviembre de 2025. [En línea]. Disponible en: <https://seh-lilha.org/construccion-modelos-regresion-multivariantes/>
- [17] K. He, X. Zhang, S. Ren, y J. Sun, «Identity Mappings in Deep Residual Networks», en *Computer Vision – ECCV 2016*, vol. 9908, B. Leibe, J. Matas, N. Sebe, y M. Welling, Eds., en *Lecture Notes in Computer Science*, vol. 9908. , Cham: Springer International Publishing, 2016, pp. 630-645. doi: 10.1007/978-3-319-46493-0_38.
- [18] M. López Santos, X. García-Santiago, F. Echevarría Camarero, G. Blázquez Gil, y P. Carrasco Ortega, «Application of Temporal Fusion Transformer for Day-Ahead PV Power Forecasting», *Energies*, vol. 15, n.º 14, p. 5232, jul. 2022, doi: 10.3390/en15145232.
- [19] S. B. Taieb y R. Hyndman, «Boosting multi-step autoregressive forecasts», en *Proceedings of the 31st International Conference on Machine Learning*, PMLR, ene. 2014, pp. 109-117. Accedido: 6 de noviembre de 2025. [En línea]. Disponible en: <https://proceedings.mlr.press/v32/taieb14.html>
- [20] «What Is Random Forest? | IBM». Accedido: 12 de diciembre de 2025. [En línea]. Disponible en: <https://www.ibm.com/think/topics/random-forest>
- [21] «Gradient Boosting with Python». Accedido: 20 de enero de 2026. [En línea]. Disponible en: https://cienciadedatos.net/documentos/py09-gradient-boosting-python-en#Gradient_Boosting_in_Python
- [22] «Interquartile Range (IQR): What it is and How to Find it», Statistics How To. Accedido: 1 de diciembre de 2025. [En línea]. Disponible en: <https://www.statisticshowto.com/probability-and-statistics/interquartile-range/>
- [23] «Modelo de Machine Learning para Interpolar Espacialmente Funciones Respuestas Impulsivas | PDF | Aprendizaje automático | Ciencia computacional», Scribd. Accedido: 2 de enero de 2026. [En línea]. Disponible en: <https://es.scribd.com/document/670410396/Modelo-de-Machine-Learning-para-interpolar-espacialmente-funciones-respuestas-impulsivas>
- [24] S. Baladram, «Decision Tree Regressor, Explained: A Visual Guide with Code Examples», Towards Data Science. Accedido: 15 de enero de 2026. [En línea]. Disponible en: <https://towardsdatascience.com/decision-tree-regressor-explained-a-visual-guide-with-code-examples-fbd2836c3bef/>
- [25] «Anaconda.org». Accedido: 26 de noviembre de 2025. [En línea]. Disponible en: <https://anaconda.org/channels/anaconda/packages/python/overview>
- [26] «Project Jupyter». Accedido: 26 de noviembre de 2025. [En línea]. Disponible en: <https://jupyter.org>

- [27] «Recursive multi-step forecasting - Skforecast Docs». Accedido: 12 de diciembre de 2025. [En línea]. Disponible en: https://skforecast.org/0.14.0/user_guides/autoregressive-forecaster.html
- [28] J. Amat Rodrigo y J. Escobar Ortiz, *skforecast*. (27 de septiembre de 2023). Zenodo. doi: 10.5281/ZENODO.8382788.
- [29] «Exogenous variables - Skforecast Docs». Accedido: 12 de diciembre de 2025. [En línea]. Disponible en: https://skforecast.org/0.14.0/user_guides/exogenous-variables
- [30] J. M., «Why So Many Time Series Models Fail in Practice», Medium. Accedido: 7 de enero de 2026. [En línea]. Disponible en: https://medium.com/@data_science_content/time-series-forecasting-pitfalls-of-the-layman-data-scientist-99bca7f7de41
- [31] «¿Por qué y cuándo escalar los datos?», Codificando Bits. Accedido: 7 de enero de 2026. [En línea]. Disponible en: <https://codificandobits.com/tutorial/por-que-cuando-escalar-los-datos/>
- [32] «XGBoost Parameters — xgboost 3.1.1 documentation». Accedido: 15 de diciembre de 2025. [En línea]. Disponible en: <https://xgboost.readthedocs.io/en/stable/parameter.html>
- [33] «GridSearchCV», scikit-learn. Accedido: 12 de enero de 2026. [En línea]. Disponible en: https://scikit-learn/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- [34] «¿Qué es el sobreajuste? | IBM». Accedido: 23 de diciembre de 2025. [En línea]. Disponible en: <https://www.ibm.com/es-es/think/topics/overfitting>